

International Conference on Machine Learning

ICML 2026 참관 리서치 리포트

포스터 · 구두 발표 리뷰

Poster & Oral Session Notes

주제 : 의료 AI · Tabular · Diffusion LM · 효율화 · 학습/평가

정리 대상 : 인상 깊었던 논문 · 발표 14편

개최지 : Seoul, Republic of Korea (2026년 7월)

작성일 : 2026년 7월

ICML 2026 · Seoul — 현장 스케치

등록 · 학회장 · Sponsor Expo



등록 데스크 — ICML 2026 Registration



학회장(COEX)에서 바라본 서울




Sponsor Expo 안내도



Expo 전시장 전경 (Two Sigma · LawZero 등)



OpenAI 부스 — Leadership Q&A



Google Research 부스



Alibaba — AI Research Tech Talk



ByteDance 부스

Contents (목차)

1 연구 동향 종합 (Overall Research Trends)	3
2 개요 및 전체 목록 (Overview)	5
3 의료·헬스케어 AI	6
3.1 AgentScore — LLM 에이전트 기반 임상 스코어링 시스템 자동 구축	6
3.2 DMAE — Latent Perturbation 기반 Cognitive-Aware 진단	6
3.3 MA-RAG — Multi-Round Agentic RAG로 의료 추론 강화	7
3.4 Lab-in-the-Loop — 데이터·AI 기반 신약개발 (키노트)	8
4 Tabular Learning	9
4.1 TopBench — Tabular QA의 암묵적 예측 추론 벤치마크	9
4.2 LassoFlexNet — Tabular 전용 유연 신경망 구조	9
4.3 Parametric Prior Mapping — 비정상 시계열 확률 예측	10
5 Diffusion Language Models	11
5.1 Scaling Beyond Masked Diffusion Language Models	11
5.2 Learning Unmasking Policies for Diffusion Language Models	11
6 LLM 효율화·프롬프트	13
6.1 CAT-Q — 저비용·정확 Ternary(1.58-bit) PTQ	13
6.2 CRL-BPT — Black-Box 프롬프트 튜닝을 위한 Curriculum RL	13
7 학습·평가·해석가능성	15
7.1 Do We Need Adam? — RLVR에서는 SGD로 충분하다	15
7.2 Less is Enough — Feature Coverage로 데이터 다양성 재정의	15
7.3 SENSEI — Knowledge-Gap Localization 기반 해석가능 AI 보조	16

1 연구 동향 종합 (Overall Research Trends)

2026년 7월 서울에서 열린 ICML 2026에서 직접 둘러본 발표 가운데 인상 깊은 14편을 골랐다. 개별 리뷰에 앞서 전체를 관통하는 연구 동향을 표로 요약하고, 이후 장에서 각 논문의 **연구 배경 · 기존 방법의 한계 · 정의한 문제 · 해결 방법**을 표로 상세히 다룬다.

동향	핵심 내용	대표 발표
성능 → 배포 가능성	높은 지표보다 임상의가 신뢰·감사·현장 실행 할 수 있는 형태를 우선. 모델 가치를 현장 의사결정에 얼마나 안전하게 꽂히는가로 측정.	AgentScore · DMAE · MA-RAG · Lab-in-the-Loop
Agentic propose-validate 표준화	“LLM이 제안 → 도구·보상이 검증” 골격이 도메인 불문 표준. 생성의 유연함을 결정론적 검증으로 감싸 신뢰성 확보.	AgentScore · MA-RAG · CRL-BPT
통념·측정의 재검토	지도학습의 직관이 RL로 이전되지 않고(AdamW→SGD), perplexity가 계열 간 비교에서 오도. “잘못된 지표 최적화 → 잘못된 결론”.	Do We Need Adam? · Scaling Beyond Masked Diffusion
Diffusion LM 성숙·효율화	perplexity 단일 지표를 넘어 scaling law · downstream · NFE 까지 다차원 비교. 생성 순서(unmasking) 자체를 학습 대상으로.	Scaling Beyond Masked Diffusion · Learning Unmasking Policies
데이터 중심 + 해석가능성	모호한 “다양성”을 feature coverage(FAC) 로 재정의($\approx 150\times$ 효율). XAI를 설명이 아닌 진단·개입(제어면) 으로 사용.	Less is Enough (FAC) · SENSEI
극한 효율화 · Tabular 재조명	QAT 없이 1.58-bit ternary 배포 실용화. tabular는 명시적 귀납 편향과 LLM 예측 추론 한계를 함께 조명.	CAT-Q · Las-soFlexNet · TopBench

Table 1: ICML 2026 주요 연구 동향 6가지와 대표 발표.

요약하면, ICML 2026의 연구들은 더 큰 모델보다 올바른 목표·형태·측정을 향하고 있었다 — 무엇을 최적화할지(coverage, deployability), 어떻게 검증할지(agentic verification), 무엇을 통념으로 두지 않을지(optimizer, perplexity)를 다시 묻는 연구들이 특히 인상 깊었다.

그 외 주목할 Spotlight (미리뷰, 관심 주제별)

ICML 2026은 별도 Oral 트랙 없이 채택작 6,796편 중 574편($\approx 8\%$)만 **Spotlight**로 선정한다 (리뷰 14편 중 4편이 Spotlight — 본문 목록·각 리뷰에 표기). 여기서는 직접 리뷰하지 않은 Spotlight 가운데 관심 주제(LLM · RAG · Medical · Interpretability) 해당작을 공식 프로그램 데이터에서 추려 둔다. LLM 계열은 136편에 달해 oral talk을 겸한 것 중 위 동향과 결이 맞는 7편만 골랐고, medical은 임상·헬스케어 중심으로 추렸다(단백질·신약 설계 계열 제외). † = oral talk 겸함.

Medical / Clinical	ClinTutor-R1 — 회진처럼 한 교수자가 다수 훈련생을 동시에 지도하는 1:N 임상 교육을 multi-agent 시뮬레이터로 모델링·학습 HypoSpace — 관측만으로 가설이 정해지지 않는 상황에서 LLM의 가설 공간 탐색·커버리지를 평가하는 진단 벤치마크 GI Auscultation — 장음(bowel sound)에서 heavy-tailed 임상 잡음을 Cauchy diffusion bridge로 분리해 비침습 진단 신호 복원 Heart Transplant (Position) — 장기 배분은 최적화가 아닌 이해관계자 게임 — 배분 정책 ML은 인센티브를 고려해야 한다 Seizure-Semiology-Suite (S^3) — 발작 비디오 438개·라벨 35K(ILAE 20개 semiology)로 MLLM의 발작 이해를 평가 SleepLM — 수면다원검사(PSG)와 자연어를 정렬한 수면 foundation model — 언어로 수면 현상을 기술·질의 SurvDiff — 중도절단(censoring) 메커니즘까지 재현하는 생존분석 전용 합성 데이터 diffusion 모델
RAG	TG-RAG[†] — expert prior 기반 thought guidance를 검색해 생성을 조향 — 특화 도메인 워크플로의 cognitive drift 완화 Train for Truth — 검색 근거와 모순 없으면 1/있으면 0의 binary reward로 online RL — 능력 보존하며 hallucination 감소 Linguistic Nepotism — 관련성이 같아도 특정 언어 문서를 우대 인용하는 multilingual RAG의 편향을 규명
Interpretability	Activation Oracles[†] — activation을 입력받아 자연어로 답하는 LatentQA를 범용화 — OOD에서도 동작하는 activation 해석기 Mechanistic Data Attribution[†] — influence function으로 해석 가능한 회로·헤드의 형성 기원을 학습 데이터까지 역추적 Long-Horizon Interpretability[†] — 긴 추론 체인에서 $O(S ^2)$ 비용과 attribution 소실을 해결한 multi-token 입력 귀속 Robust Harmful Features[†] — jailbreak은 safety feature를 지우는 게 아니라 특정 attention head를 선택적으로 억제함을 규명 Compositional Explanations[†] — 뉴런의 논리 규칙(compositional) 설명에 beam search 없이 최적성 보장을 부여 LM Circuits Are Sparse — MLP 뉴런 기저가 SAE만큼 sparse함을 최초 실증 — SAE 없이 뉴런 기반 circuit tracing SVD Interpretability — 보조 모델(SAE) 학습 없이 MLP 가중치의 SVD만으로 해석하는 training-free 기법 Concept Bottleneck MoE — CBM의 예측기를 전문가 혼합·다양한 함수형으로 일반화해 정확도와 해석성 양립 Time Series Saliency Maps — Integrated Gradients를 가역 변환 도메인(주파수 등)으로 일반화한 시계열 귀속
LLM	The Flexibility Trap[†] — any-order 생성이 스도쿠엔 유리하나 수학·코딩 일반 추론에선 오히려 해가 됨을 규명 WeDLM[†] — 표준 causal attention만으로 diffusion 디코딩 — prefix KV cache를 유지해 최적화 AR 엔진급 속도 How Much Can LMs Memorize?[†] — 암기를 unintended memorization vs generalization으로 분리해 모델 저장 용량 측정 Reasoning Collapse[†] — multi-turn agent RL에서 추론이 입력 무관 템플릿으로 붕괴 — $H(Z X) \cdot I(X; Z)$ 분해로 탐지 OMAC[†] — LLM 멀티에이전트 시스템의 구조·프롬프트를 체계적으로 최적화하는 범용 프레임워크 Evolving Rubrics[†] — 검증 어려운 long-form deep research를 정책과 함께 진화하는 rubric 보상으로 RL 학습 ReQAT[†] — FP4 실패가 숫자·연산자 같은 low-entropy 토큰에 집중됨을 규명 — 겨냥 QAT로 full-precision 추론 복원

Table 2: 미리뷰 Spotlight 중 관심 주제 선별 — 한줄 요약 (원제목·링크는 papers/README.md).

2 개요 및 전체 목록 (Overview)

각 항목은 발표장에서 촬영한 포스터/슬라이드와 함께, **연구 배경 · 기존 방법의 한계 · 정의한 문제 · 해결 방법**을 표로 요약하고 핵심 결과를 덧붙였다. 전문용어 · 메서드 · 데이터셋 · 메트릭명은 원문(영문)을 유지한다. 정리 순서는 다섯 주제를 따른다: (1) 의료 · 헬스케어 AI, (2) Tabular Learning, (3) Diffusion Language Models, (4) LLM 효율화 · 프롬프트, (5) 학습 · 평가 · 해석가능성. 본문에서 다룬 논문 원문 PDF는 [icml_2026/papers/](#) 아래에 함께 모아 두었다(키노트 및 OpenReview 전용 2편 제외).

분야	제목 / 약칭	소속	형태
의료 AI	AgentScore	U. Cambridge	포스터
	DMAE (Cognitive-Aware Diagnosis)	CUHK-Shenzhen	포스터
	MA-RAG	Nanjing / Huawei	포스터
	Lab-in-the-Loop	Genentech (키노트)	키노트
Tabular	TopBench	Nanjing (LAMDA)	포스터
	LassoFlexNet	RBC Borealis	포스터
Diffusion LM	Scaling Beyond Masked Diffusion	Cornell / NVIDIA	포스터
	Learning Unmasking Policies	Apple / MIT / UvA	Spotlight
효율화/프롬프트	CAT-Q (ternary PTQ)	Intel Labs China	Spotlight
	CRL-BPT	Shandong UFE	포스터
학습/평가	Do We Need Adam? (RLVR)	UIUC	Spotlight
	Less is Enough (FAC coverage)	UGA / HK PolyU	Spotlight
	SENSEI	USC	포스터
	Parametric Prior Mapping (PPM)	Central South U	포스터

Table 3: 리뷰 대상 논문 · 발표 14편.

3 의료·헬스케어 AI

가장 눈여겨본 주제다. 공통 키워드는 **임상 배포 가능성(deployability)**과 **에이전트 기반 추론(agentic reasoning)**이었다 — 성능 지표를 넘어 임상 의사 신뢰·검증·배포할 수 있는 형태를 지향하는 흐름이 뚜렷했다.

3.1 AgentScore — LLM 에이전트 기반 임상 스코어링 시스템 자동 구축

Silas Ruhrberg Estévez, Christopher Chiu, Mihaela van der Schaar · van der Schaar Lab, University of Cambridge · 포스터 · arXiv:2601.22324

연구 배경	임상 현장은 CURB-65처럼 소수의 해석 가능한 규칙으로 된 compact scoring system 에 의존한다. 예측력 높은 ML 모델은 memorability · auditability · bedside 실행 제약과 어긋나 실제 진료에 정착하지 못한다.
기존 방법의 한계	RiskSLIM · FasterRisk는 non-unit 정수 가중치 라 암산 부담이 크다. Optimal Checklists 등은 미리 정의된 고정 feature 위에서만 최적화해, raw 변수로부터 임상 규칙(생리 비율 · 시계열 변화 등)을 자동 구성 · 선택하지 못한다.
정의한 문제	raw 변수로부터 rule 구성과 subset 선택을 동시에 최적화해, 크기 $ S \leq m$ · unit weight 같은 hard deployability 제약을 만족하는 unit-weighted N-of-M checklist scoring system 을 학습.
해결 방법	propose-validate 루프 (GPT-5 백본): LLM agent가 제한된 clinical grammar 안에서 후보 규칙을 제안 → deterministic validation(AUROC $\geq \tau$, Jaccard 중복 제거) + clinical plausibility agent가 검증 → score assembly agent가 조립. threshold는 Youden's J로 데이터에서 결정.

핵심 결과. MIMIC-IV · eICU 8개 과제 평균 AUROC **0.71** — RiskSLIM 대비 +0.05, FasterRisk 대비 +0.03 ($p < 0.001$). 외부 검증에서 SOFA/SAPS-I guideline보다 높음(ICU 0.701 vs 0.660). 임상의 18명 중 67%가 AgentScore 선호, **배포 선호 81% vs 19%**.




Figure 1: AgentScore 포스터 (U. Cambridge). 규칙 제안 · 결정론적 검증 · 임상의 리뷰 · 프라이버시 감사까지 배포 관점 전 과정을 다룬다.

3.2 DMAE — Latent Perturbation 기반 Cognitive-Aware 진단

Yuting Yan, Yinghao Fu, Wendi Ren, Haozhou Gao, Shuang Li · CUHK-Shenzhen / City University of Hong Kong · 포스터
(OpenReview: rEzGzLnVC)

연구 배경	희귀질환은 증상이 흔해 보이고 핵심 검사가 누락되기 쉽다. AI와 임상 의사의 모두 혼란 진단에 고착되는 cognitive anchoring 이 오진을 부른다.
기존 방법의 한계	정확도 중심 진단 모델은 예측 확률만 제시할 뿐, 어떤 검사가 빠졌고 왜 rare 진단을 놓치는지 설명하지 못해 임상 의사결정 자체를 교정하지 못한다.
정의한 문제	disease-symptom 구조와 임상 의사의 진단 패턴을 학습한 latent 공간에서, 누락된 증거를 드러내 rare-yet-plausible 진단을 대비적으로 부각하는 counterfactual 시나리오 생성.
해결 방법	DMAE : latent $Z(\text{rare vs. common})$ 에 attention mask를 씌우고 $\Delta Z^* = \arg \max \text{Entropy}$ 로 교란해 누락 검사를 복원, rare 가설로 재유도.

핵심 결과. 7개 코호트(공개 4 + 비공개 3)에서 rare 진단 탐지력을 높이면서 common 진단 정확도는 유지. 포스터 기준 physician-reviewed 사례의 약 90%가 임상적으로 타당·유용으로 평가.




Figure 2: DMAE 포스터 (CUHK-Shenzhen). Acromegaly 사례에서 OGTT-GH 누락을 보정하자 rare 확률이 0.53 → 1.00으로 이동.

3.3 MA-RAG — Multi-Round Agentic RAG로 의료 추론 강화

Wenhao Wu, Zhentao Tang, Yafu Li, Shixiong Kai, Mingxuan Yuan, Zhenhong Sun, Chunlin Chen, Zhi Wang · Nanjing University / Huawei Noah's Ark Lab / CUHK / ANU · 포스터 · arXiv:2603.03292

연구 배경	LLM은 의료 QA에서 높은 추론력을 보이지만 hallucination 과 outdated knowledge가 안전-민감 의료 현장에 위험을 준다. RAG가 이를 완화하나 복잡한 multi-step 추론에는 부족하다.
기존 방법의 한계	single-round RAG는 복잡 추론에서 실패하고 noise를 유입한다. FLARE·DRAGIN 등 adaptive RAG는 token-level 신호 (confidence·entropy)에 의존하는데, LLM은 high confidence로도 hallucinate해 신호를 신뢰할 수 없다.
정의한 문제	multi-round adaptive RAG를 iterative context optimization으로 정식화. noisy token 신호 대신 후보 응답 간 semantic conflict 를 신호 로 삼아, 외부 근거와 내부 reasoning history를 반복 진화시켜 consensus로 수렴.
해결 방법	Solver → Retrieval → Ranking 3-에이전트: 다양한 N 개 후보 생성 → conflict를 conflict-aware query로 바꿔 의료 corpus 검색 → intrinsic entropy + extrinsic verifier로 history 재정렬. conflict를 residual로 보는 boosting 메커니즘.

핵심 결과. 7개 의료 벤치에서 backbone(Qwen3-8B) 대비 평균 +6.8. MA-RAG-ext 62.2로 최강 RAG baseline(TC-RAG 56.9)보다 +5.3. MedXpertQA 상대 37% 향상(22.2 vs 16.1), Qwen3-32B에서도 +5.5.




Figure 3: MA-RAG 포스터. Solver/Retrieval/Ranking 에이전트 구조와 후두신경 사례 기반 다회전 추론.

3.4 Lab-in-the-Loop — 데이터·AI 기반 신약개발 (키노트)

Aviv Regev (EVP & Head of Genentech Research and Early Development, gRED; Broad Institute; MIT) · ICML 2026 Invited Talk

연구 배경	신약 후보의 90%+가 전임상·임상에서 실패한다. 생물학 실험과 임상 데이터는 방대하지만 다음 실험 설계로 충분히 환류되지 못한다.
기존 방법의 한계	전통적 신약개발은 실험→분석→가설이 단선적으로 흐르고, AI 모델은 대개 사후 분석에 머물러 실험 설계를 능동적으로 이끌지 못한다.
정의한 문제	실험·데이터·AI를 하나의 폐루프 로 묶어, 모델이 다음 실험을 예측·설계하도록 만드는 것 (target discovery부터 drug development까지 전 단계).
해결 방법	Lab-in-the-Loop : Human biology / experiments → Data → AI/ML → 다음 실험 설계로 순환하는 구조를 Genentech 전반에 구축.

핵심 결과. 정량 벤치마크보다, Genentech의 대규모 lab-in-the-loop 구축 사례와 신약개발 전 단계에 걸친 적용 방향·비전을 제시.




Figure 4: Aviv Regev 키노트 “Lab in the Loop” — 실험·데이터·AI의 순환 루프.

4 Tabular Learning

트리 기반 모델이 여전히 강한 tabular 영역에서, **귀납적 편향(inductive bias)의 명시적 설계**와 **LLM의 예측적 추론 한계**를 각각 파고든 발표들이 눈에 띄었다.

4.1 TopBench — Tabular QA의 암묵적 예측 추론 벤치마크

An-Yang Ji, Jun-Peng Jiang, De-Chuan Zhan, Han-Jia Ye · Nanjing University (LAMDA) · 포스터 · arXiv:2604.28076 · github.com/LAMDA-Tabular/TopBench

연구 배경	LLM 기반 Table QA는 명시적 정보 검색·집계에서 발전했다. 그러나 실제 산업 질의는 healthcare·finance·daily consulting에서 historical table로부터 관측되지 않은 값을 추론 하는 implicit predictive 성격을 띤다.
기존 방법의 한계	WTQ·TabFact·Spider·BIRD 등 기존 벤치마크는 explicit fact 검색·집계만 평가한다. implicit predictive 시나리오 데이터가 없고, 중간 reasoning(intent 오인 vs 예측 modeling 결함)을 구분하지 못한다.
정의한 문제	implicit predictive TQA를 2단계 추론 으로 형식화 — intent abstraction(질의에서 table에 없는 target feature profile x' 추출) → predictive inference($f: x \rightarrow y$ 학습 후 $y' = f(x')$ 추정). Single-Point / Decision / Treatment Effect / Ranking&Filtering 4개 task.
해결 방법	TopBench : 35개 source table·3개 도메인·779개 샘플. User/Data Holder 이중 관점 질의, text-based·agentic ReAct 두 패러다임, 통계 지표 + LLM-as-a-Judge 하이브리드 평가.

핵심 결과. 9개 모델 대부분 **0.60 미만** — 최고 Gemini 3 Flash도 Single-Point 0.65. Decision·Treatment는 무작위 추측 수준. agentic 실행 시 GPT-5.2 Treatment가 0.51→0.65로 개선.




Figure 5: TopBench 포스터 (Nanjing U., LAMDA). 4계층 task taxonomy와 text/agentic 실험 결과.

4.2 LassoFlexNet — Tabular 전용 유연 신경망 구조

Kry Yik Chau Lui, Cheng Chi, Kishore Basu, Yanshuai Cao · RBC Borealis (Toronto) · 포스터 · arXiv:2603.20631 · github.com/BorealisAI/lassoflexnet

연구 배경	DNN이 vision·language를 지배하지만 tabular data에서는 XGBoost·CatBoost 같은 tree 모델에 뒤처진다 — 무관 feature 강건성·axis alignment·localized irregular 함수 학습이라는 inductive bias 결핍 때문.
기존 방법의 한계	LassoNet은 linear skip으로 Lasso를 딥러닝에 확장했으나 현대 tabular 벤치서 자주 underperform. raw-input 상관에 의존해 nonlinear importance를 못 잡고, joint Hier-Prox 최적화가 불안정하다. TabPFN·TabR은 규모 제약.
정의한 문제	다섯 inductive bias (무관 feature 강건성 · axis alignment · localized irregularity · feature heterogeneity · training stability)를 native하게 인코딩해, tree를 능가하면서 Lasso 수준의 sparse 선택·해석성을 유지하는 tabular-native 아키텍처.
해결 방법	represent-then-select : Per-Feature Embedding(수치형 PLE·범주형 one-hot+ResNet) + Tied Group Lasso 선택 + cross-feature MLP-Mixer(τ soft-curriculum) + EMA 기반 Seq-Hier-Prox-Adam-EMA optimizer.

핵심 결과. 3개 벤치 52개 데이터셋에서 leading tree 모델을 매칭·능가(최대 **10% 상대 향상**). noise feature selection에서 oracle two-stage 파이프라인을 제치고 50% noise 8/12·75% noise 7/12 top-3. California-housing ablation RMSE 0.4047(EMA 제거 0.4195).




Figure 6: LassoFlexNet 포스터 (RBC Borealis). represent-then-select 구조, ablation, TabZilla/TabRed 벤치마크.

4.3 Parametric Prior Mapping — 비정상 시계열 확률 예측

Jinglin Li, Jun Tan, Qi Fang, Ning Gui · Central South University · 포스터 · arXiv:2605.23402

연구 배경	확률적 MTS forecasting은 예측 불확실성을 특성화해 weather·finance·transportation 같은 고위험 의사결정에 핵심. non-stationary 동역학은 진화하는 분포·시변 stochasticity의 정확한 추적을 요구한다.
기존 방법의 한계	DeepAR 등 parametric은 고정 output family (예: Gaussian)와 실제 분포의 불일치로 제약. diffusion/flow generative는 데이터·연산 과다에 느리다. TMDM·NsDiff는 rigid prior (고정 window 분산)로 분포 이동에 적응 못해 miscalibration.
정의한 문제	시변·진화하는 불확실성을 포착하는 non-stationary 확률적 MTS forecasting에서 표현력·robustness·계산 효율 을 동시에 달성하는 문제.
해결 방법	PPM : parametric 구조 prior를 generative 과정에 주입 — encoder가 conditional Gaussian prior의 통계량을 추론·resampling하고, 학습 가능한 push-forward mapping (2-layer MLP)이 sample-based 예측 분포로 사상. KDE-NLL + MSE anchor의 hybrid objective.

핵심 결과. 7개 실세계 데이터셋에서 second-best 대비 **CRPS 최대 31.2%·QICE 44.3% 감소**, diffusion 대비 추론 약 2–100× 가속 (ETTh1 CRPS 0.337, Traffic 0.252). prior ablation에서 +PM이 Gaussian·Uniform 모두 크게 개선.




Figure 7: Parametric Prior Mapping 포스터 (Central South U). prior mapping 구조와 ETT 벤치마크.

5 Diffusion Language Models

Diffusion 기반 언어모델의 **scaling law 성숙**과 **unmasking(생성 순서) 정책 학습**이 화두였다.

5.1 Scaling Beyond Masked Diffusion Language Models

Subham Sekhar Sahoo, Jean-Marie Lemerrier, Zhihan Yang, Justin Deschenaux, Jingyu Liu, John Thickstun, Ante Jukić · Cornell Tech / Cornell / EPFL / NVIDIA · 포스터 · arXiv:2602.15014

연구 배경	Diffusion LM은 병렬·고속 생성으로 AR 모델을 대체할 후보이며, 그중 Masked diffusion(MDLM) 이 강한 perplexity로 현재 지배적 위치. d-LLM은 통상 perplexity 같은 likelihood 지표로 비교된다.
기존 방법의 한계	perplexity는 같은 family 안에서는 유효하나, 계열마다 likelihood bound가 달라 cross-family 비교에서는 오도될 수 있고 inference 속도·샘플 품질도 반영하지 못한다. 기존 scaling 연구는 대부분 MDLM에만 집중.
정의한 문제	Masked diffusion이 non-autoregressive 생성의 지배적 패러다임인가, 더 큰 설계공간의 현 선두일 뿐인가 — MDLM · Duo(uniform-state) · Eso-LM(interpolating) 세 계열의 최초 IsoFLOP scaling law 로 검증.
해결 방법	FLOPs를 맞춘 IsoFLOP 비교와 compute-optimal scaling law 적합. MDLM에 low-variance(cross-entropy) 학습 목적 도입, Gen PPL·throughput으로 speed-quality Pareto frontier 구성, 전 방법을 1.7B로 확장.

핵심 결과. low-variance 목적으로 MDLM이 약 12% FLOPs-효율 향상(AR 대비 필요 compute $16\times \rightarrow 14\times$). AR perplexity 매칭에 Duo 약 $23\times$ · Eso-LM 약 $32\times$. 반전: SFT 후 **Duo가 GSM8K 65.8**로 AR 62.9 · MDLM 58.8 · Eso-LM 33.4를 모두 능가.




Figure 8: “Scaling Beyond Masked Diffusion” 포스터. 좌: 생성 방식 비교, 우: scaling law와 downstream 평가.

5.2 Learning Unmasking Policies for Diffusion Language Models

Metod Jazbec, Theo X. Olausson, Louis Béthune, Pierre Ablin, Michael Kirchhof 외 · Apple / University of Amsterdam / MIT · Spotlight (oral talk) · arXiv:2512.09106

연구 배경	Diffusion LLM(dLLM/MDM)은 여러 task에서 AR 성능을 따라잡으며 효율적 추론을 약속한다. 매 diffusion step에서 어떤 토큰을 unmask할지 정하는 sampling 절차가 핵심 설계 요소.
기존 방법의 한계	confidence thresholding(Fast-dLLM) 등 heuristic sampler는 척도·threshold λ 의 수작업 튜닝이 필요하고, block size가 커지거나 semi-AR 영역을 벗어나면 random 이하로 저하되며, NFE(compute)를 늘려도 이득이 없다.
정의한 문제	정확도와 효율을 모두 만족하는 최적 unmasking 순서는 무엇인가 — MDM sampling을 dLLM이 environment인 MDP로 정식화하고 unmasking policy를 RL로 학습.
해결 방법	dLLM은 동결. token confidence 벡터 → Bernoulli unmask 결정을 내리는 경량 single-layer transformer policy(약 300K params, dLLM의 0.01% 미만)를 GRPO로 학습 — correctness $\times$ step penalty의 multiplicative reward(α 로 속도-정확도 조절).

핵심 결과. semi-AR(BL=32)에서 Fast-dLLM 등 SOTA heuristic과 대등, full-diffusion(BL=256)에서는 능가 — GSM8K를 약 12 NFE에 약 50%(heuristic $\leq 30\%$). 모델(LLaDA→Dream)·시퀀스 길이 전이도 확인.



Figure 9: Spotlight talk 슬라이드 — masked diffusion의 any-order 생성 개념(learned unmasking policy).

6 LLM 효율화 · 프롬프트

상용·대형 모델의 배포 비용 제약 아래, **극한 양자화와 블랙박스 프롬프트 최적화**로 효율과 실용성을 끌어올린 발표들이다.

6.1 CAT-Q — 저비용·정확 Ternary(1.58-bit) PTQ

Shigeng Wang, Chao Li, Yangyuxuan Kang, Jiawei Fan, Anbang Yao · Intel Labs China · Spotlight (oral talk · Poster #3006) · arXiv:2606.26650 · github.com/IntelChina-AI/BitTern

연구 배경	LLM은 메모리·연산 비용이 커 배포가 어렵다. ternary(1.58-bit) quantization 은 FP16 대비 10배+ 메모리 절감과 곱셈→덧셈 대체라는 hardware-friendly 이점을 갖는 극단적 압축 기법.
기존 방법의 한계	SOTA ternary(BitNet 1.58-bit·TriLM·Tequila)는 QAT 의존 — 수백 B tokens 재학습에 막대한 비용, 소규모 ($\leq 7B$)에 국한. 일반 PTQ는 4-bit엔 통해도 2-bit 이하에서 성능 붕괴 .
정의한 문제	512 sequences 규모 calibration set만으로 임의 architecture·규모의 pretrained LLM을 PTQ 방식으로 ternary화. 난제는 (1) 분포 misalignment로 인한 정보 손실, (2) non-differentiable 극저비트의 수렴 곤란.
해결 방법	LM(Learnable Modulation) : $\delta_\mu, \delta_\alpha, \delta_\Delta$ 로 weight 분포·threshold를 조정해 outlier 억제. ST(Softened Ternarization) : differentiable→hard 2단계 relay transition으로 안정 수렴. 둘을 sliding-layer reconstruction에 결합.

핵심 결과. 512 calibration samples($\approx 1M$ tokens)로 100B tokens 학습한 BitNet을 능가 — **학습 토큰 약 $10^5 \times$ 절감**. ternary화를 처음으로 **14B~235B**로 확장, Llama2-70B 정확도 하락 3.81%. 10개 LLM·5개 zero-shot 벤치서 검증.




Figure 10: CAT-Q(BitTern) Spotlight talk “Takeaways” 슬라이드 (Intel Labs China).

6.2 CRL-BPT — Black-Box 프롬프트 튜닝을 위한 Curriculum RL

Shuai Gong, Chaoran Cui, Xiaolin Dong, Chunyun Zhang, Linwei Fan · Shandong University of Finance and Economics · 포스터 (OpenReview/ICML poster 66416)

연구 배경	상용 LLM/VLM은 파라미터·gradient가 비공개다. API 접근만으로 입력 프롬프트를 최적화하는 Black-Box Prompt Tuning(BBPT) 수요가 크다.
기존 방법의 한계	soft prompt는 연속 벡터라 해석성이 없고 , hard(discrete) prompt 탐색은 대량 API 호출 이 필요하다. 초기의 과도한 탐색은 학습을 불안정하게 하고 overfitting을 유발.
정의한 문제	해석 가능한 프롬프트 생성과 API 효율을 동시에 달성하는 BBPT를, LLM 에이전트의 탐색 스케줄 문제로 정식화.
해결 방법	imitation → innovation 커리큘럼 : Dynamic Curriculum Schedule로 Imitation Loss(ROUGE-L)와 Innovation Loss를 점진 전환. Historical Loss Normalization + Relative Reward Calibration으로 안정화, black-box CLIP 위에서 RL 학습.

핵심 결과. 13개 데이터셋 few-shot에서 Zero-shot CLIP·BAR·BlackVIP·BPTVLM·ZIP·StablePrompt 대비 우수(포스터 기준 Caltech 94.6 등). 해석 가능한 프롬프트를 생성하면서 API 효율 개선.




Figure 11: CRL-BPT 포스터 (Shandong UFE). imitation→innovation 커리큘럼과 13개 데이터셋 결과.

7 학습 · 평가 · 해석가능성

옵티마이저 · 데이터 · 해석가능성 등 **학습과 평가의 전제 자체를 재검토한** 발표들이다.

7.1 Do We Need Adam? — RLVR에서는 SGD로 충분하다

Sagnik Mukherjee, Lifan Yuan, Pavan Jayasinha, Dilek Hakkani-Tür, Hao Peng · UIUC · Spotlight (oral talk) · arXiv:2602.07729

연구 배경	verifiable reward 기반 RL(RLVR)은 LLM 학습의 핵심 단계가 되었다. 그러나 RL 최적화 관행은 근본적으로 다른 next-token-prediction 단계(pretraining · SFT)의 관행 — 특히 메모리 부담이 큰 AdamW — 을 그대로 답습한다.
기존 방법의 한계	AdamW의 momentum · adaptive LR은 SFT/pretraining에 맞춰진 것으로 optimizer state에 파라미터당 약 12 바이트를 요구. “SGD는 대형 transformer에 부적합”하다는 통념은 supervised 학습에서 도출된 결론 이라 RLVR에 그대로 적용되지 않을 수 있다.
정의한 문제	RLVR 학습에 adaptive learning rate와 momentum이 정말 필요한가 — 메모리 효율적인 SGD가 RLVR에서 AdamW를 대등하게, 혹은 더 잘 수행할 수 있는가.
해결 방법	RLVR이 Adam의 momentum · adaptive LR에서 얻는 이득이 SFT 보다 작다는 가설. AdamW · SGD · SGD+Momentum · RMSProp을 math · coding · RLVE × Qwen3 · Llama × GRPO · PPO에서 비교하고 update sparsity · effective rank 를 분석.

핵심 결과. SGD가 AdamW를 대등 · 능가(coding Qwen3-1.7B pass@1 평균 +8.7%). momentum · adaptive LR은 무익하거나 유해. SGD는 파라미터의 **0.02–0.46%만 갱신**(AdamW 대비 최대 약 $500\times$ sparse), GPU 메모리 15.7 GB 절감. PPO · 장기 학습에도 일반화.



Figure 12: Spotlight talk 세션 전경 — 도입부 슬라이드 “AdamW Is the Status Quo for Good Reasons”.

7.2 Less is Enough — Feature Coverage로 데이터 다양성 재정의

Zhongzhi Li, Xuansheng Wu, Yijiang Li, Lijie Hu, Ninghao Liu · University of Georgia / UCSD / MBZUAI / HK PolyU · Spotlight (oral talk) · arXiv:2602.10388

연구 배경	post-training 데이터의 diversity 는 LLM downstream 성능에 결정적이다. 그러나 다양·포괄적(long-tailed 포함) 데이터 수집은 비용이 크고, diverse 데이터를 원리적으로 구성하는 방법이 핵심 과제.
기존 방법의 한계	기존 diversity metric은 text·embedding 공간의 변이만 측정 — “text variance $\neq$ task variance”로 downstream과 상관이 약하다. gradient 기반 방법은 checkpoint 의존으로 전이가 어렵고, 단순 LLM 합성은 중복·분포 편향을 낳는다.
정의한 문제	모델 내부 feature 공간에서 diversity를 정량화 — 생성 데이터가 커버하는 task-relevant feature 비율 FAC(Feature Activation Coverage) 를 정의하고, SAE feature 공간의 distribution gap 최소화를 목표로 삼는다.
해결 방법	FAC Synthesis : 모델 activation에 SAE를 학습해 interpretable feature를 얻고 → seed 데이터에서 missing feature 를 진단 → feature별 contrastive pair를 few-shot demonstration 삼아 해당 feature를 활성화하는 샘플을 합성(diagnose-then-synthesize).

핵심 결과. FAC는 downstream 성능과 강한 상관(Pearson $r=0.95$). **2K 합성 샘플**로 300K를 쓰는 MAGPIE에 필적 — 약 150× 데이터 효율. Toxicity AUPRC +23.63·Reward Modeling +13.32 등 4개 task 전부 향상, cross-model transfer 확인.




Figure 13: Spotlight talk 결론 슬라이드 — Coverage 목표, 150× 데이터 효율, diagnose-then-synthesize 페루프.

7.3 SENSEI — Knowledge-Gap Localization 기반 해석가능 AI 보조

Ayano Hiranaka, Ya-Chuan Hsu, Stefanos Nikolaidis, Erdem Biyik, Daniel Seita · USC · 포스터 · arXiv:2606.05602

연구 배경	human-AI 협업에서 AI 보조는 alert · steering 같은 behavioral feedback로 즉각 실수를 막는다. 그러나 반복 실수를 유발하는 근본 misconception 을 고치지 못하면 장기적 개선이 어렵다(learning sciences 관점).
기존 방법의 한계	shared autonomy · steering은 “ move ”만 고칠 뿐 사람의 task “ mind ”를 교정하지 못하고 재사용 가능한 진단도 없다. ITS/misconception 기법은 대규모 주석이나 instructor-authored bug library에 의존.
정의한 문제	long-horizon 의사결정 보조를 knowledge correction 으로 정식화 — behavior alignment를 structured knowledge alignment로 근사해, expert · student 지식의 불일치(knowledge gap)를 localize하고 최소 correction을 합성.
해결 방법	2-stage SENSEI : PDDL로 지식 표현, frozen CodeT5+ encoder 위에서 (1) localization network가 misaligned component 탐지 → (2) latent editor가 expert embedding을 편집해 decoder가 student 지식 생성. single-misconception + mixup loss로 zero-shot compositional generalization.

핵심 결과. Breakfast/Overcooked/Rover에서 Sys-F1 **0.709/0.726/0.561**로 최고 균형, localize 후 Edit-acc 0.97–1.0. 1-misconception만 학습해도 2–3개 중첩에 zero-shot 일반화. 사용자 20명 연구에서 **misconception 90% 교정**(Sys-rec 0.895), IoU 0.736→0.844.




Figure 14: SENSEI 포스터 (USC). 관찰→진단→보조 프레임워크와 PDDL 기반 실험.